

ATIVIDADE PRÁTICA – Engenharia de Dados

Disciplina: MS SQL Server Operação

Tema: PNAD Covid-19

Fonte pública: Microdados do **PNAD Covid-19** (IBGE), disponíveis em CSV no portal gov.br: [IBGE - PNAD Covid-19](https://dados.gov.br/dataset/pnad-covid-19)

OBJETIVO

Desenvolver um projeto completo de ETL e Data Warehouse utilizando a base pública PNAD COVID-19 do IBGE.

O aluno deverá aplicar conceitos de:

- Engenharia de Dados
- ETL
- Staging Area
- Data Warehouse
- Stored Procedures e Functions no SQL Server

CONTEXTO

A PNAD COVID-19 foi uma pesquisa realizada pelo IBGE em 2020 para avaliar os impactos da pandemia na saúde, emprego e renda da população brasileira. Os dados possuem granularidade por pessoa.

ARQUITETURA DO PROJETO

```
CSV (IBGE)
  ↓
STAGING (dados quase brutos)
  ↓
Stored Procedures (transformação)
  ↓
DATA WAREHOUSE (modelo dimensional)
```

ESTRUTURA DE PASTAS DO PIPELINE (PYTHON)

```

pnad_covid_etl/
├── data/
│   └── raw/
├── pipeline/
│   ├── extract.py
│   ├── load_staging.py
│   └── run_etl.py
├── sql/
│   ├── staging.sql
│   ├── dw.sql
│   └── procedures.sql
└── utils/
    ├── config.py
    └── db_connection.py

```

MODELO DE DADOS – STAGING

Tabela: staging.pnad_covid_pessoa

A staging deve manter os nomes e estrutura próximos da fonte original.

Coluna	Tipo	Descrição
NU_ANO	INT	Ano de referência da pesquisa
NU_MES	INT	Mês da entrevista
UF	CHAR(2)	Sigla da Unidade da Federação
CO_MUNICIPIO	INT	Código IBGE do município
ID_DOMICILIO	BIGINT	Identificador do domicílio
ID_PESSOA	BIGINT	Identificador da pessoa
SEXO	CHAR(1)	Sexo do entrevistado
IDADE	INT	Idade em anos

ESCOLARIDADE	INT	Nível de escolaridade
OCUPACAO	INT	Situação de ocupação
RENDIMENTO	DECIMAL(12,2)	Rendimento mensal
SINTOMAS	INT	Indicador de sintomas
INTERNADO	CHAR(1)	Indica internação
TESTE_COVID	CHAR(1)	Indica teste de COVID
DT_CARGA	DATETIME	Data da carga

MODELO DIMENSIONAL – DATA WAREHOUSE

Dimensões obrigatórias

dim_tempo

Campo	Tipo de Dado	Descrição
sk_tempo	INT (IDENTITY)	Chave substituta da dimensão tempo
nu_ano	INT	Ano de referência da pesquisa
nu_mes	INT	Mês de referência da pesquisa
no_mes	VARCHAR(20)	Nome do mês (ex.: Janeiro)

dim_municipio

Campo	Tipo de Dado	Descrição
sk_municipio	INT (IDENTITY)	Chave substituta do município
co_municipio	INT	Código IBGE do município
sg_uf	CHAR(2)	Sigla da Unidade da Federação
no_municipio	VARCHAR(150)	Nome do município normalizado
uq_dim_municipio	UNIQUE	Garante unicidade do código IBGE

dim_pessoa

Campo	Tipo de Dado	Descrição
sk_pessoa	INT (IDENTITY)	Chave substituta da pessoa
sexo	CHAR(1)	Sexo do indivíduo (M/F)
faixa_etaria	VARCHAR(30)	Faixa etária derivada da idade
escolaridade	INT	Código do nível de escolaridade

Tabela Fato

fato_pnad_covid

Campo	Tipo de Dado	Descrição
sk_tempo	INT	FK para dim_tempo
sk_municipio	INT	FK para dim_municipio
sk_pessoa	INT	FK para dim_pessoa
ocupacao	INT	Situação ocupacional
rendimento	DECIMAL(12,2)	Rendimento mensal
sintomas	INT	Indicador de sintomas
internado	CHAR(1)	Indicador de internação
teste_covid	CHAR(1)	Indicador de teste COVID

FUNCTIONS A SEREM IMPLEMENTADAS

1) Função de normalização textual

Responsabilidade:

- Remover espaços extras
- Converter texto para formato capitular (Title Case)

2) Função de faixa etária

Regras:

- 0-17 → Criança / Adolescente
- 18-29 → Jovem Adulto
- 30-59 → Adulto
- 60+ → Idoso

STORED PROCEDURES A SEREM IMPLEMENTADAS

1) usp_carregar_dim_municipio

Responsabilidades:

- Ler dados da staging
- Agrupar por código IBGE
- Normalizar nome do município
- Inserir apenas registros novos

2) usp_carregar_dim_pessoa

Responsabilidades:

- Criar faixas etárias
- Padronizar sexo e escolaridade
- Gerar chave substituta

3) usp_carregar_dim_tempo

Responsabilidades:

- Ler os campos **NU_ANO** e **NU_MES** da tabela `staging.pnad_covid_pessoa`
- Gerar combinações únicas de **ano/mês**
- Inserir registros na tabela `dw.dim_tempo`
- Preencher o campo **no_mes** com o nome do mês
- Evitar duplicidade de registros

4) usp_carregar_fato

Responsabilidades:

- Resolver chaves das dimensões
- Inserir métricas
- Garantir integridade referencial

PIPELINE PYTHON

Responsável por:

- Ler arquivo CSV
- Carregar dados na staging
- Executar stored procedures do DW

CRITÉRIOS DE AVALIAÇÃO

- Modelagem (20)
- Procedures e Functions (40)
- Pipeline Python (40)

CONCLUSÃO

Este projeto simula um cenário real de engenharia de dados, onde dados públicos são transformados em informação analítica por meio de boas práticas de ETL e Data Warehouse.