

1. Cenário do projeto

Tema: Educação básica no Brasil

Fonte pública: Microdados do **Censo Escolar da Educação Básica** (INEP), disponíveis em CSV no portal gov.br. [Serviços e Informações do Brasil+1](#)

2. Informações Gerais do Projeto

Item	Descrição
Nome do Projeto	ETL e Data Warehouse para Dados Públicos da Educação Básica
Fonte de Dados	Microdados do Censo Escolar da Educação Básica – INEP
Tecnologias	Python, MS SQL Server, Stored Procedures, Functions, Triggers
Objetivo Principal	Construir um pipeline robusto para ingestão, tratamento, qualidade e disponibilização analítica de dados educacionais
Responsável Técnico	Engenheiro de Dados / Equipe de Analytics
Versão do Documento	1.0

2. Escopo do Projeto

- Coleta automatizada dos microdados do Censo Escolar (arquivos CSV).
- Armazenamento da camada *raw* em diretório específico no ambiente de dados.
- Criação de área Staging no SQL Server para recepção direta dos dados.
- Desenvolvimento de pipeline Python para leitura, limpeza e carga incremental.

- Implementação de tratamento de dados no SQL Server por meio de:
 - Stored Procedures (ETL, SCD, cálculo de métricas)
 - Functions (normalização, mapeamento, business rules)
 - Triggers (auditoria e validação)
- Construção de um Data Warehouse (DW) no modelo estrela.
- Disponibilização dos dados para relatórios, dashboards e análise exploratória.


3. Objetivos do Projeto

- Criar pipeline escalável e versionável para ingestão anual dos dados educacionais.
- Garantir qualidade e integridade dos dados com regras centralizadas no banco.
- Implementar modelo analítico padronizado aplicável a diferentes anos do Censo.
- Prover rastreabilidade total da carga (log, auditoria e monitoramento).

4. Requisitos do Projeto

ID	Requisito
RF01	O sistema deve realizar download anual dos microdados do Censo Escolar.
RF02	O pipeline deve carregar os dados brutos para a camada Staging no SQL Server.
RF03	As cargas devem ser processadas por ano, de forma incremental.
RF04	O DW deve possuir dimensões normalizadas e fato central de matrículas.
RF05	Stored procedures devem executar todo o processamento entre Staging e DW.
RF06	Funções devem padronizar textos, códigos e auxiliar a geração de SKs.
RF07	Triggers devem registrar dados inválidos e inconsistências.
RF08	O pipeline Python deve orquestrar a carga e a execução das procedures.

5. Arquitetura do Sistema



6. Modelo Lógico do DW

6.1. Tabelas Dimensionais

dim_escola

Campo	Tipo	Descrição
sk_escola	INT PK	Surrogate key
co_entidade	BIGINT	Identificador natural INEP
no_entidade	VARCHAR(200)	Nome padronizado
co_municipio	INT	FK para dimensão município
tp_rede	TINYINT	Rede de ensino

dt_inicio	DATE	Início da validade (SCD2)
dt_fim	DATE	Fim da validade
fl_ativo	CHAR(1)	S / N

dim_municipio

Campo	Tipo	Descrição
sk_municipio	INT PK	
co_municipio	INT	Código IBGE
uf	CHAR(2)	Unidade federativa
nome_municipio	VARCHAR(200)	

dim_etapa_ensino

Campo	Tipo
sk_etapa_ensino	INT PK
tp_etapa_ensino	INT
ds_etapa_ensino	VARCHAR(200)

Dim_tempo

Campo	Tipo
sk_tempo	INT PK
ano	INT
mes	TINYINT
dia	TINYINT
dt_calendario	DATE

6.2. Tabela Fato

fact_matricula

Campo	Tipo	Descrição
sk_tempo	INT FK	
sk_escola	INT FK	
sk_municipio	INT FK	
sk_etapa_ensino	INT FK	
qt_matricula	INT	
dt_carga	DATETIME2	

7. Dicionário de Dados (Resumo)

7.1. Fonte (Staging) – stg.censo_escolar_matricula

Campo	Tipo	Origem
ano_censo	INT	NU_ANO_CENSO (INEP)
co_entidade	BIGINT	CO_ENTIDADE
no_entidade	VARCHAR	NO_ENTIDADE
co_municipio	INT	CO_MUNICIPIO
uf	CHAR(2)	SG_UF
tp_rede	TINYINT	TP_REDE
tp_etapa_ensino	INT	TP_ETAPA_ENSINO
qt_matricula	INT	QT_MATRICULA

8. Regras de Transformação

8.1. Normalização

Regra	Descrição
RT01	Remover acentos de textos.
RT02	Aplicar TRIM e UPPER em nomes de escolas e municípios.
RT03	Garantir UF sempre em formato "UF" válido.

8.2. Dimensões (SCD tipo 2)

Regra	Descrição
RT10	Em caso de modificação no nome da escola, encerrar o registro anterior (dt_fim).
RT11	Criar novo registro com fl_ativo = 'S'.

8.3. Fato

Regra	Descrição
RT20	Cargas devem ser somadas por ano/escola/etapa.
RT21	Registros com qt_matricula <= 0 devem ser enviados ao log.

9. Triggers e Governança de Dados

9.1. Trigger de Validação

- Registrar em tabela `dw.log_matricula_invalida` qualquer matrícula inválida.
- Não impede a carga (modo NON-BLOCKING), mas gera auditoria.

9.2. Trigger de Auditoria

- Registrar timestamp e usuário de inserção em tabelas de dimensão.

10. Pipeline Python

10.1. Responsabilidades

Etapa	Descrição
Extract	Baixar CSV do INEP.
Load Staging	Carregar dados brutos em <code>stg.censo_escolar_matricula</code> .
Transform & Load DW	Executar stored procedure <code>dw.usp_processar_censo_escolar_ano</code> .
Logging	Registrar execução em tabela <code>dw.log_execucao_etl</code> .

11. Entregáveis

- Scripts SQL: criação de Staging, DW, procedures, functions e triggers.
- Código Python de ingestão.
- Dicionário de dados.
- Documento de arquitetura (este documento).
- Pipeline funcional demonstrável em sala ou ambiente corporativo.